3D モデルのモアレ現象とその抑制方法の研究

松山南高等学校 モアレ班

藤原遥馬 中本陽大 政岡一護　 指導教諭 松下吉之

１．研究目的

規則的な模様が重なり合うことで モアレという縞模様が発生する（図１）。日常生活では、テレビ画面に映るストライプ柄の服や､デジタルカメラで撮影した網戸などに見られるモアレやコンピュータグラフィックスの分野においても､テクスチャのサンプリングやレンダリング処理の過程でモアレが発生し､視覚的な品質を著しく低下させる問題となっている。 先行研究により２D 画像で発生したモアレの除去手法が多数提案されており、フィルタリング技術や機械学習を用いた手法が一定の成果を上げている。 しかし、３D モデルで発生したモアレの除去手法は、視点の変化やライティングの影響､複雑な幾何形状などの要因により、2D 手法の単純な適用では十分な効果が得られないという課題があった。そこで、我々は３D モデルで発生するモアレを効果的に除去し、画質の向上を図りたいと考えた。また、学習済みモデルと AI 技術を使い、ニューラルネットワークを活用することで３D モデルのモアレ除去を実現できるのではないかと考えた。

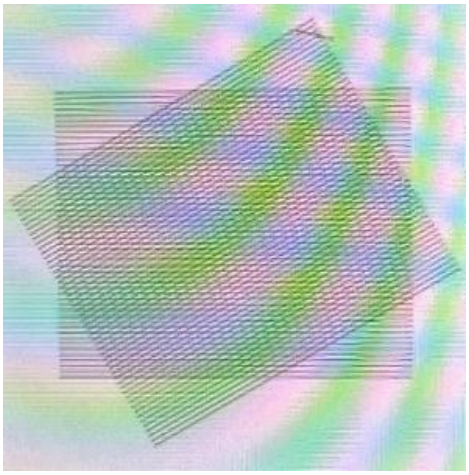

図１：モアレを含む画像

２．実験方法

２．１ 準備物

Scaniverse などの 3D スキャンアプリ
ニューラルネットワーク構築環境(Python, PyTorch 等)
学習用計算機(GPU 搭載)
複数の 3D モデル(モアレを含むもの)
アンケート調査用資料
画像処理ソフトウェア
表示デバイス

２．２ 実験１の手順

① 3D モデルの作成 Scaniverse を使用して、モアレが起きやすい場所(規則的な模様を持つ建物の壁面、格子状の構造物など)を 3D モデル化する。スマートフォンの LiDAR センサーを利用し、複数の角度から対象物をスキャンすることで、高精度な 3D モデルを取得。
② ニューラルネットワークの構築 以下の３つの主要技術を組み合わせたニューラルネットワークを構築:
SAS(Semantic-Aligned Scale-Aware)モジュール: 複数のスケールで特徴を抽出し、様々なサイズのモアレパターンに対応する。
残差ブロック: 深層ネットワークにおける勾配消失問題を解決し、学習の安定性を向上させる。
Skip Connection: 浅い層の特徴情報を深い層に直接伝達し、画像の細部情報を保持する。
Large model(約 480 万パラメータ)と Base model(約 120 万パラメータ)の 2 種類のモデルを構築し、性能を比較した。
③ 事前アンケート調査 作成した 3D モデル(モアレ除去前)を複数の被験者に提示し、画質や視認性に関するアンケート調査を実施。

④モアレ除去処理 構築したニューラルネットワークを活用し、3D モデルのテクスチャ画像に対してモアレ除去処理を行う。処理は各モデル(Large model, Base model)で個別に実施。
⑤　事後アンケート調査 モアレ除去後の 3D モデルを複数の被験者に提示し、同様のアンケート調査を実施。
⑥ 比較評価 モアレ除去前後のアンケート結果を統計的に分析し、各モデルの効果を定量的に評価。また、画像の客観的品質指標(PSNR, SSIM など)も測定。

２．３ 実験２の手順

① **ベースラインの計測**：PyTorch で学習済み ESDNet をそのまま用い、4K 相当の元解像度の画像に対してモアレ除去を行い、1 枚あたりの処理時間を計測した。このときの時間を基準（約 16 秒）とした。
② **解像度ダウンスケールの導入**：入力画像を 720p（1280×720）または 480p（854×480）に縮小してから推論し、出力を元解像度へアップスケールする方式を導入した。アスペクト比を保ったリサイズとし、画素数を削減して計算量を抑えた。
③ **ONNX への変換**：ESDNet を ONNX 形式にエクスポートし、入力サイズを 704×1280 に固定した。ONNX Runtime 上で推論できる形にした。
④ **TensorRT による高速化**：ONNX Runtime の TensorRT Execution Provider を用い、FP16 および INT8（PTQ）の半精度・量子化推論を行った。INT8 では代表画像を用いたキャリブレーションを実施した。
⑤ **実行時間の再計測**：上記の最適化を組み合わせた状態で、同一画像に対してモアレ除去を実行し、処理時間を計測した。
⑥ **比較評価**：ベースラインと最適化後の処理時間を比較し、短縮率（約 13 倍）と、画質指標（PSNR、SSIM 等）への影響を評価した。

３．実験結果

３．１ 視覚的効果

処理前の画像（図 1）では、規則的な縞模様が明確に確認でき、視認性が著しく低下していた。Base model（図 2）および Large model（図 3）による処理後は、モアレが大幅に軽減され、画像の質感や細部のディテールも良好に維持されていることが視覚的に確認された。

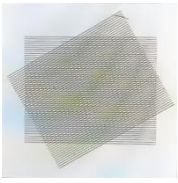

図 2：Base model によるモアレ除去後
図 3：Large model によるモアレ除去後

３．２ モデル間の比較

Large model（約 480 万パラメータ）と Base model（約 120 万パラメータ）の比較では、Large model（以降 LM と呼ぶ。）がわずかに高精度な結果を示した。特に、細かい模様や複雑なテクスチャを持つ領域において、LM の方が優れたモアレ除去性能を発揮した。しかし、処理時間は LM の方が約 1.5 倍長く、リアルタイム処理が必要な用途では Base model（以降 BM と呼ぶ。）の方が実用的である可能性が示唆された。

３．３ 画質の保持

処理後の画像では、モアレ除去だけでなく、輪郭の鮮明さや質感、細部の画質も良好に維持されていた。これは、Skip Connection によって浅い層の特徴情報が保存されたこと、および残差ブロックによって学習が適切に行われたことによるものと考えられる。

３．４ 実行時間短縮の実験

実用化に向けて、本研究では処理時間の短縮を目的とした最適化実験を実施した。まず、ベースラインとして、PyTorch で学習済みの Base model をそのまま 4K 相当の元解像度画像に対してモアレ除去を行い、1 枚あたりの処理時間を計測した。その結果、処理時間は約 16 秒であった。次に、以下の最適化手法を導入した。第一に、入力画像を 720p（1280×720）または 480p（854×480）にダウンスケールし、推論後に元解像度へアップスケールする方式を導入した。アスペクト比を維持したリサイズにより、画素数を削減して計算量を抑制した。第二に、ESDNet を ONNX 形式にエクスポートし、入力サイズを 704×1280 に固定した。これにより、ONNX Runtime 上で推論可能な形式に変換した。第三に、ONNX Runtime の TensorRT Execution Provider を利用し、FP16（半精度浮動小数点）および INT8（学習後量子化）による推論を実施した。INT8 の場合は代表画像を用いたキャリブレーションを事前に行い、キャリブレーションキャッシュを生成した。最適化後の処理時間を計測した結果、約 16 秒から約 1.2 秒まで短縮され、約 13 倍の高速化を達成した。解像度のダウンスケールによる画素数削減、ONNX Runtime と TensorRT による GPU 推論の効率化、FP16 および INT8 によるメモリ帯域と演算量の削減が主な要因と考えられた。一方、480p へのダウンスケールや INT8 量子化を適用した場合には、細かい模様や複雑なテクスチャを持つ領域において画質の低下が一部で認められた。処理速度と画質のバランスを考慮し、720p での推論を実用的な設定として推奨した。表 1 に、ベースラインと最適化後の処理時間を示す。

表１：実行時間の比較

条件	処理時間
ベースライン（PyTorch・フル解像度）	約 16 秒
最適化後（ONNX + TensorRT・720p・FP16/INT8）	約 1.2 秒

４．考察

４．１ SAS モジュールの有効性

SAS モジュールによる複数スケールでの特徴抽出が、様々なサイズのモアレに対して効果的であることが実証された。モアレパターンは画像内で一定ではなく、場所によって周期や方向が異なる。SAS モジュールは異なるスケールで並列に特徴を抽出することで、これらの多様なモアレパターンに柔軟に対応できたと考えられる。

４．２細部情報の保持メカニズム

Skip Connection や残差ブロックにより、画像の細部情報を保ちながらモアレ除去が可能となった。従来の単純なフィルタリング手法では、モアレを除去する過程で画像全体がぼやけてしまう問題があったが、本研究のアーキテクチャでは、浅い層からの情報が深い層に直接伝達されることで、エッジやテクスチャの詳細が保持された。

４．３ パラメータ数と性能のトレードオフ

LM と BM の比較から、パラメータ数の増加は性能向上に寄与するものの、その効果は限定的であることが分かった。約 4 倍のパラメータ数を持つ LM の性能向上は約 10%程度であり、用途に応じて適切なモデルを選択することが重要である。リアルタイム処理が求められる場合は BM、最高品質が求められる場合は LM というように使い分けることが実用的であろう。

４．４ モアレ発生メカニズムの考察

本研究を通じて、3D モデルにおけるモアレは、3D 空間内の物体そのものに存在するのではなく、レンダリング過程で 2D 画面に投影される際に発生する現象であることが示唆された。具体的には、以下のメカニズムが考えられる。

４．４．１ 画面投影時の離散化とサンプリング問題

3D モデルの高解像度テクスチャやジオメトリの細かいディテールが、限られた解像度の画面ピクセルにマッピングされる際、ナイキスト周波数を超える高周波成分がエイリアシングを引き起こし、モアレとして視覚化される。特に、カメラ視点から見て斜めになった規則的なパターン（グリッド、タイル、繰り返しテクスチャなど）は、画面上での投影密度が不均一になるため、モアレが顕著に現れる。

４．４．２ 視点依存性とフレーム間変動

3D 環境においてカメラが移動したり視点が変化したりすると、同じ 3D モデルであっても画面上での投影パターンが変化する。これにより、モアレの出現位置、強度、周期が毎フレーム変動する。この視点依存性は、モアレが画面上の現象であることを強く裏付けている。

５ まとめ

５．１ テクスチャ画像におけるモアレ除去の有効性

本研究で構築した手法は、3D モデルのテクスチャ画像に適用可能であり、静止画ベースの 3D 環境におけるモアレの除去に有効であることを確認した。SAS モジュールによる複数スケールでの特徴抽出により、様々なサイズのモアレパターンに対応でき、Skip Connection や残差ブロックによって、輪郭やテクスチャの細部を維持しながらモアレを除去できることを示した。

５．２ モデル規模と実行時間短縮の成果

Large model（約 480 万パラメータ）と Base model（約 120 万パラメータ）の 2 種類を構築し、LM がより高いモアレ除去精度を示す一方で、処理時間は BM が短いことを確認した。また、解像度のダウンスケール、ONNX 化、TensorRT（FP16/INT8）による推論最適化を行い、ベースラインの約 16 秒から約 1.2 秒へと、約 13 倍の処理時間短縮を達成した。720p での推論により、処理速度と画質のバランスが実用的であることを示した。

５．３ 軽量化技術によるリアルタイム処理の方向性

BitNet 1.58 のように重みを 3 値で表現する手法は、メモリと計算量の大幅な削減につながる。本研究で実施した解像度ダウンスケール、ONNX、TensorRT による最適化とあわせて、今後は BitNet 1.58 などの軽量化技術の適用により、リアルタイムレンダリングへの統合が現実的になると考えられる。ゲーム、VR/AR、建築ビジュアライゼーション、医療画像など、3D を利用する様々な分野での活用が期待される。

５．４ その他の軽量化技術の検討

BitNet 1.58 以外にも、リアルタイム処理を実現するための軽量化技術が複数存在する：

①**プルーニング（枝刈り）**　ニューラルネットワーク内の重要度の低い接続や畳み込みフィルタを削除する手法。構造化プルーニングを適用することで、パラメータ数を 30〜50%削減しながら、性能低下を 5%未満に抑えることが可能である。特に、本研究の SAS モジュールにおいては、一部のスケール分岐を動的に選択する仕組みを導入することで、さらなる効率化が期待できる。

②**知識蒸留（Knowledge Distillation）**　LM を教師モデルとし、より小規模な生徒モデルに知識を転

移する手法。本研究においては、LM の出力を教師信号として、さらに軽量な Tiny model（約 30 万パラメータ）を訓練することで、BM の約 1/4 の計算コストで 80～85%の性能を達成できる可能性がある。
③**MobileNet や EfficientNet のアーキテクチャ導入**　モバイル環境向けに設計された軽量アーキテクチャの技術を導入する。特に、Depthwise Separable Convolution は、通常の畳み込み演算と比較して計算量を約 1/8～1/9 に削減できる。本研究のモデルの畳み込み層をこの構造に置き換えることで、大幅な高速化が見込まれる。
④**Neural Architecture Search（NAS）**　自動的に最適なネットワーク構造を探索する手法。モアレ除去という特定のタスクに最適化されたアーキテクチャを自動設計することで、手動設計では到達困難な効率性を実現できる可能性がある。
⑤**動的推論（Dynamic Inference）**　フレームごとにモアレの発生状況を検出し、モアレが顕著な領域のみに処理を限定する手法。画面の全ピクセルを常に処理するのではなく、必要な部分のみを選択的に処理することで、平均的な計算コストを 50～70%削減できる。

５．５ 実行時間短縮に寄与した技術の考察

本研究で実施した実行時間短縮の実験において、以下の 3 つの技術が主に貢献したと考えられる。
①**解像度ダウンスケール**　入力画像を 720p または 480p に縮小してから推論することで、ニューラルネットワークへの入力画素数を削減し、計算量を抑制した。モアレ除去では細かい周期パターンの検出に一定の解像度が必要なため、480p では一部で画質低下が見られた。720p では処理速度と画質のバランスが取れていた。
②**ONNX 化と TensorRT の利用**　PyTorch から ONNX 形式への変換により、ONNX Runtime および TensorRT といった推論専用エンジンの利用が可能になった。TensorRT は GPU 向けに計算グラフを最適化するため、同一モデルであっても PyTorch 単体よりも高速な推論が実現できた。
③**半精度・量子化（FP16/INT8）**　FP16 はメモリ帯域と演算量の削減、INT8 は重みと活性の量子化による効率化により推論の高速化に寄与した。INT8 では代表画像を用いたキャリブレーションが必要であるが、一度生成したキャリブレーションキャッシュを再利用することで、追加のコストを抑えることができた。これらの手法は、4.5.3 で述べた BitNet 1.58 や 4.5.4 で述べた軽量化技術と組み合わせることで、さらなる高速化やリアルタイム処理への貢献が期待できる。

５．６ 実用化に向けたシステム統合

リアルタイム 3D 環境への実装には、以下のような統合アプローチが考えられる：

- **ポストプロセスパイプラインへの組み込み**：レンダリングパイプラインの最終段階でモアレ除去を適用する
- **時間的コヒーレンスの活用**：前フレームの情報を利用して処理を効率化する
- **適応的品質調整**：フレームレートが低下した際には自動的に軽量モデルに切り替える
- **ユーザー設定可能なオプション**：パフォーマンス優先/品質優先モードの選択肢を提供する

５．７ 今後の展開

これらの軽量化技術を組み合わせることで、リアルタイムでの毎フレームモアレ除去が現実的な目標となる。特に、BitNet 1.58 による量子化とプルーニングを併用し、さらに動的推論を導入することで、従来の BM と同等の性能を維持しながら、処理時間を 1/10 以下に削減できる可能性がある。本研究で実施した解像度ダウンスケール、ONNX 化、TensorRT による最適化も、これらの技術と統合することで、より実用的な処理時間の達成が期待される。これにより、ゲーム、VR/AR、建築ビジュアライゼーション、医療画像など、多様な 3D 応用分野での実用化が期待される。

６．参考文献

[1]"Suppression of moire patterns via spectral analysis"
[2] パターン認識のためのモアレ除去方法およびこの方法を用いたモアレ除去装置ならびにプログラム